

Report progetto Deep Learning

Rilevazione e classificazione dei danni alla carrozzeria con l'utilizzo di YOLO11n

1. Descrizione del problema e obiettivo del progetto

L'obiettivo del progetto è costruire un sistema di **object detection** capace di individuare automaticamente i danni presenti sulla carrozzeria di un'automobile a partire da immagini.

Il problema non consiste soltanto nel capire se un'immagine contiene o meno un danno, ma anche nel determinare **dove si trova il danno** e **a quale tipologia appartiene**. Per questo motivo non è stato scelto un semplice modello di classificazione, ma un modello di object detection.

Un classificatore tradizionale assegna un'etichetta all'intera immagine, ad esempio "auto danneggiata" o "auto non danneggiata". Nel nostro caso, invece, lo scopo è localizzare il danno all'interno dell'immagine tramite un **bounding box**, cioè un riquadro che delimita l'area danneggiata, e assegnare a quel riquadro una classe specifica.

Il sistema sviluppato riconosce tre categorie di danno:

Classe
crack
dent
scratch

Per svolgere questo compito è stato utilizzato il modello **YOLO11n**, una versione leggera della famiglia YOLO, adatta a compiti di rilevamento rapido degli oggetti e utilizzabile anche in ambienti con risorse limitate, come Google Colab.

YOLO, acronimo di **You Only Look Once**, è una famiglia di modelli per object detection. Il suo funzionamento si basa sull'analisi dell'immagine in un unico passaggio, restituendo direttamente le classi degli oggetti rilevati, le coordinate dei bounding box e un valore di confidenza associato a ogni predizione.

Nel contesto di questo progetto, YOLO11n viene usato per analizzare immagini di automobili e individuare eventuali danni alla carrozzeria. Per ogni danno rilevato, il modello produce:

- un **bounding box**, che indica la posizione del danno nell'immagine;
- una **classe**, tra crack, dent e scratch;
- un **valore di confidenza**, che rappresenta quanto il modello è sicuro della predizione.

Il modello è stato addestrato per **100 epoche**, utilizzando immagini ridimensionate a **1024 pixel** e una **batch size pari a 16**. L'obiettivo dell'addestramento è stato quello di adattare YOLO11n al dataset specifico dei danni automobilistici, in modo da permettere al modello di riconoscere pattern visivi diversi, come crepe, ammaccature e graffi.

2. Dataset e preparazione dei dati

Il dataset utilizzato per il progetto è stato scaricato in un formato compatibile con **YOLO**, quindi ogni immagine è associata a un file di annotazione contenente le informazioni sui bounding box e sulle relative classi.

Le immagini sono suddivise in due insiemi principali: **training set** e **validation set**. Nel notebook non è presente una cartella di test separata; per questo motivo, la valutazione delle prestazioni del modello è stata effettuata sul **validation set**.

La struttura del dataset è la seguente:

Split	Immagini	Annotazioni
Train	3239 immagini	3239 label
Validation	902 immagini	902 label
Test	non presente	non presente

Il **training set** è stato utilizzato per addestrare il modello, mentre il **validation set** è stato usato per controllare le prestazioni durante e dopo l'addestramento.




Figura 1 - Distribuzione delle annotazioni e posizione/dimensione dei bounding box nel dataset.

La **Figura 1** mostra la distribuzione delle annotazioni presenti nel dataset e fornisce informazioni sulla posizione e sulla dimensione dei bounding box.

Questo tipo di grafico è utile perché permette di analizzare alcune caratteristiche importanti del dataset, come:

- la distribuzione delle classi crack, dent e scratch;
- la posizione più frequente dei danni all'interno delle immagini;
- la dimensione media dei bounding box;
- l'eventuale presenza di sbilanciamenti tra le classi.

La figura mostra che il dataset è abbastanza bilanciato tra le tre classi crack, dent e scratch. I bounding box sono spesso concentrati nella zona centrale delle immagini e, nella maggior parte dei casi, hanno dimensioni ridotte. Questo indica che molti danni sono piccoli e quindi il task di object detection risulta abbastanza complesso, soprattutto per danni sottili o poco evidenti come i graffi.

3. Stato dell'Arte e Soluzioni usate in Letteratura

Nel campo del riconoscimento automatico dei danni automobilistici da immagini, in letteratura vengono utilizzati diversi approcci basati su Computer Vision e Deep Learning.

Una prima soluzione consiste nell'utilizzo di modelli di **classificazione tramite CNN**, cioè reti neurali convoluzionali capaci di assegnare un'etichetta all'intera immagine, ad esempio "auto danneggiata" o "auto non danneggiata". Questo approccio è semplice, ma non è sufficiente quando è necessario localizzare con precisione il punto in cui si trova il danno.

Un'altra possibile soluzione è la **segmentazione**, che consente di individuare in modo più preciso l'area danneggiata a livello di pixel. Questo metodo può fornire risultati più dettagliati rispetto ai bounding box, ma richiede annotazioni più accurate e un costo computazionale maggiore.

Infine, molti lavori utilizzano modelli **pre-addestrati** su grandi dataset generici e successivamente adattati al dominio specifico tramite **fine-tuning**. Questa strategia permette di ridurre i tempi di addestramento e migliorare le prestazioni quando il dataset disponibile non è molto grande.

Nel presente progetto è stato scelto un approccio basato su **object detection con YOLO11n**, poiché consente di ottenere contemporaneamente la classe del danno, la sua posizione nell'immagine e un valore di confidenza, mantenendo un modello leggero e compatibile con le risorse disponibili su Google Colab.

4. Modello e addestramento

Per il progetto è stato utilizzato **YOLO11n**. La scelta di YOLO11n è adatta al progetto perché consente di rilevare gli oggetti in modo veloce, mantenendo un modello relativamente piccolo e semplice da addestrare, salvare e riutilizzare.

Il modello è stato inizializzato a partire da pesi pre-addestrati e poi adattato al dataset dei danni automobilistici tramite una fase di fine-tuning. In questo modo, YOLO11n ha imparato a riconoscere le tre classi specifiche del progetto: crack, dent e scratch.

L'addestramento è stato eseguito su **Google Colab** utilizzando una GPU **Tesla T4**. Le immagini sono state ridimensionate a **1024 pixel**, una dimensione più alta rispetto al valore standard usato spesso nei training YOLO. Questa scelta è utile perché i danni alla carrozzeria possono essere piccoli o poco evidenti, quindi una risoluzione maggiore permette al modello di conservare più dettagli visivi.

I principali parametri utilizzati sono riportati nella tabella seguente:

Parametro	Valore
Modello	YOLO11n
Task	Object detection
Epoche	100
Dimensione immagini	1024
Batch size	16
Ottimizzatore	AdamW
GPU	Tesla T4
File modello finale	Best.pt

Durante il training, il modello ha aggiornato progressivamente i propri pesi cercando di ridurre gli errori di localizzazione e classificazione. Al termine dell'addestramento, YOLO ha salvato automaticamente i pesi del modello nella cartella del progetto su Google Drive.

In particolare, sono stati generati due file principali:

File	Significato
best.pt	modello migliore ottenuto durante il training
last.pt	modello salvato all'ultima epoca

Per la valutazione finale e per le predizioni è stato utilizzato il file **best.pt**, perché rappresenta il modello con le migliori prestazioni ottenute durante l'addestramento.

5. Andamento del training




Figura 2 - Andamento delle loss e delle metriche durante le 100 epoche di training.

La **Figura 2** mostra l'andamento dell'addestramento del modello YOLO11n durante le **100 epoche di training**. Il grafico riporta sia le **loss**, cioè gli errori commessi dal modello, sia le principali **metriche di valutazione**, usate per misurare la qualità delle predizioni.

Le loss sono divise tra training set e validation set. Le loss sul training set indicano quanto il modello sta imparando sulle immagini usate per l'addestramento, mentre le loss sul validation set indicano quanto il modello riesce a generalizzare su immagini non usate direttamente per aggiornare i pesi.

Le principali loss mostrate sono:

Loss	Significato
box_loss	misura l'errore nella posizione dei bounding box predetti
cls_loss	misura l'errore nella classificazione del danno
df_l_loss	misura l'errore nella precisione della forma e dei bordi del bounding box

Nel grafico si nota che le loss di training diminuiscono progressivamente durante le epoche. Questo indica che il modello sta imparando a riconoscere meglio i pattern visivi presenti nelle immagini, migliorando sia nella localizzazione sia nella classificazione dei danni.

Anche le loss di validazione hanno un andamento complessivamente decrescente. Questo è un segnale positivo, perché significa che il modello non sta semplicemente memorizzando il training set, ma sta imparando caratteristiche utili anche per immagini diverse. Se le loss di training fossero diminuite mentre quelle di

validazione fossero aumentate molto, ci sarebbe stato un possibile problema di overfitting. In questo caso, invece, le curve mostrano un comportamento abbastanza regolare.

Le metriche di valutazione sono rappresentate nella tabella seguente:

Metrica	Significato
Precision	indica quante predizioni fatte dal modello sono corrette
Recall	indica quanti danni reali il modello riesce a trovare
mAP50	misura la qualità delle detection con soglia IoU pari a 0.50
mAP50-95	misura la qualità delle detection con soglie IoU più severe, da 0.50 a 0.95

Precision e recall vanno lette insieme. Un modello può avere precision alta ma recall bassa se fa poche predizioni, ma molto sicure. Al contrario, può avere recall alta ma precision bassa se rileva tanti possibili danni, includendo però anche molti errori.

La metrica **mAP50** valuta la qualità complessiva della detection considerando corretta una predizione quando il bounding box predetto ha una sovrapposizione sufficiente con il bounding box reale. Questa sovrapposizione si misura tramite la **IoU**, cioè Intersection over Union. Una IoU pari a 0.50 significa che il box predetto e quello reale si sovrappongono almeno per il 50%.

La metrica **mAP50-95** è più severa, perché non valuta il modello solo con soglia IoU 0.50, ma considera più soglie, da 0.50 fino a 0.95. Per questo motivo il valore di mAP50-95 è normalmente più basso rispetto al mAP50. Questa metrica dà un'indicazione più precisa sulla qualità dei bounding box: non basta trovare circa la zona del danno, ma bisogna localizzarla con maggiore accuratezza.

Nel grafico si osserva che **precision**, **recall**, **mAP50** e **mAP50-95** aumentano durante l'addestramento. Questo significa che, con il passare delle epoche, il modello diventa progressivamente più capace di individuare i danni, classificarli correttamente e disegnare bounding box più accurati.

Nelle ultime epoche, le curve tendono a stabilizzarsi. Questo comportamento indica che il modello ha raggiunto una fase di **convergenza**, cioè continua ad apprendere, ma i miglioramenti diventano sempre più piccoli. È un andamento normale: nelle prime epoche il modello impara rapidamente, mentre nelle epoche finali affina progressivamente le predizioni.

Nel complesso, la **Figura 2** mostra un andamento positivo: le loss diminuiscono e le metriche aumentano. Questo conferma che l'addestramento è avvenuto correttamente. Tuttavia, i valori finali delle metriche non sono molto elevati, quindi il modello rappresenta una buona base di partenza, ma presenta ancora margini di miglioramento, soprattutto nel riconoscimento di danni piccoli, poco visibili o difficili da distinguere, come i graffi sottili e le ammaccature leggere.

6. Risultati finali della validazione

Al termine dell'addestramento è stato validato il modello migliore salvato durante il training, cioè il file **best.pt**. La validazione è stata effettuata sul **validation set**, composto da 901 immagini valide e 1973 istanze annotate.

I risultati ottenuti sono riportati nella tabella seguente:

Classe	Immagini	Istanze	Precision	Recall	mAP50	mAP50-95
Tutte le classi	901	1973	0.541	0.439	0.443	0.239
crack	490	605	0.684	0.651	0.679	0.424
dent	375	525	0.519	0.429	0.426	0.199
scratch	263	843	0.419	0.237	0.223	0.0947

Osservando i risultati complessivi, il modello ottiene una **precision pari a 0.541**, una **recall pari a 0.439**, un **mAP50 pari a 0.443** e un **mAP50-95 pari a 0.239**.

Questi valori mostrano che il modello riesce a individuare diversi danni, ma non raggiunge ancora prestazioni molto elevate, soprattutto se si considera la metrica più severa mAP50-95.

La classe riconosciuta meglio è **crack**, cioè le crepe. Questa classe ottiene i risultati migliori, con:

- precision pari a **0.684**;
- recall pari a **0.651**;
- mAP50 pari a **0.679**;
- mAP50-95 pari a **0.424**.

Questo significa che il modello riesce a rilevare le crepe con una buona affidabilità rispetto alle altre classi. Probabilmente ciò dipende dal fatto che le crepe hanno spesso forme più marcate e visivamente riconoscibili.

La classe **dent**, cioè le ammaccature, ottiene risultati intermedi. Il mAP50 è pari a **0.426**, mentre la recall è pari a **0.429**. Questo indica che il modello riesce a riconoscere alcune ammaccature, ma può avere difficoltà nei casi in cui la deformazione della carrozzeria è leggera o poco evidente.

La classe più problematica è **scratch**, cioè i graffi. Questa classe ha un mAP50 pari a **0.223** e una recall pari a **0.237**.

Il valore basso della recall indica che molti graffi presenti nelle immagini non vengono rilevati correttamente dal modello.

In sintesi, i risultati mostrano che il modello ha imparato a riconoscere i danni alla carrozzeria, ma con prestazioni diverse a seconda della classe. Le crepe sono la categoria più semplice da rilevare, le ammaccature hanno una difficoltà intermedia, mentre i graffi rappresentano la classe più complessa. Questo suggerisce che eventuali miglioramenti futuri dovrebbero concentrarsi soprattutto sulla classe scratch, ad esempio aumentando la qualità delle annotazioni, aggiungendo più immagini rappresentative o usando un modello YOLO più grande.

7. Confusion Matrix




Figura 3 - Matrice di confusione con valori assoluti.




Figura 4 - Matrice di confusione normalizzata.

Le **Figure 3 e 4** mostrano le **matrici di confusione** ottenute durante la validazione del modello. Questi grafici permettono di analizzare in modo più dettagliato il comportamento del modello, mostrando quali classi vengono riconosciute correttamente e in quali casi si verificano errori.

Nelle matrici, le classi reali si trovano sull'asse orizzontale, mentre le classi predette dal modello si trovano sull'asse verticale. La **diagonale principale** rappresenta le predizioni corrette: più alti sono i valori sulla diagonale, migliore è la capacità del modello di riconoscere quella classe.

I valori fuori dalla diagonale indicano invece errori di classificazione o rilevazioni mancate. In particolare, la classe background rappresenta i casi in cui il modello non associa correttamente un oggetto a una delle classi di danno oppure produce una predizione non corrispondente a un'annotazione reale.

La **Figura 3** mostra la matrice di confusione con i valori assoluti. Si può osservare che il modello riconosce correttamente:

Classe	Predizioni corrette
crack	413
dent	253
scratch	252

La classe crack è quella con il numero maggiore di riconoscimenti corretti. Questo conferma quanto già visto nelle metriche finali, dove crack ottiene i valori migliori di precision, recall e mAP.

La classe dent viene riconosciuta correttamente in 253 casi, ma presenta anche diversi errori verso il background. Questo significa che alcune ammaccature non vengono rilevate oppure non vengono localizzate correttamente.

La classe scratch è quella più problematica. Anche se alcune istanze vengono riconosciute correttamente, molti graffi vengono associati al background. Questo indica che il modello spesso non riesce a rilevare i graffi come veri danni.

La **Figura 4** mostra la stessa informazione in forma normalizzata, quindi i valori sono espressi come proporzioni. Questo rende più semplice confrontare le prestazioni tra le diverse classi.

Dalla matrice normalizzata si osserva che:

Classe reale	Percentuale riconosciuta correttamente
crack	0.68
dent	0.48
scratch	0.30

Il valore **0.68** per crack indica che circa il 68% delle crepe viene riconosciuto correttamente. Questo conferma che crack è la classe più stabile per il modello.

Per dent, il valore corretto è **0.48**, quindi circa il 48% delle ammaccature viene riconosciuto correttamente. Una parte significativa viene invece confusa con il background.

Il caso più critico è scratch, con un valore corretto pari a **0.30**. Questo significa che solo circa il 30% dei graffi viene riconosciuto correttamente, mentre una parte molto alta viene classificata come background. In particolare, il valore **0.68** nella riga background e nella colonna scratch indica che molti graffi reali non vengono rilevati dal modello.

Questi risultati sono coerenti con le metriche viste in precedenza.

L'errore più evidente non è tanto la confusione diretta tra una classe di danno e un'altra, ma la confusione con il **background**. Questo significa che il modello spesso non sbaglia semplicemente etichetta, ma non riesce proprio a rilevare alcuni danni, soprattutto i graffi.

8. Curve di valutazione

8.1 Curva Precision-Recall




Figura 5 - Curva Precision-Recall per le tre classi.

La Figura 5 mostra la **curva Precision-Recall** ottenuta durante la validazione del modello. Questa curva permette di analizzare il compromesso tra **precision** e **recall** al variare della soglia di confidenza utilizzata dal modello per accettare o scartare una predizione.

La curva Precision-Recall è quindi utile perché mostra come cambia il comportamento del modello quando si modifica la soglia di confidenza. Se la soglia è alta, il modello accetta solo predizioni molto sicure: in questo caso la precision tende ad aumentare, ma la recall può diminuire perché alcuni danni vengono scartati. Se invece la soglia è più bassa, il modello rileva più oggetti, quindi la recall può aumentare, ma la precision può diminuire perché crescono anche le predizioni errate.

Una curva più alta e più vicina all'angolo in alto a destra indica prestazioni migliori, perché significa che il modello riesce a mantenere contemporaneamente alta precision e alta recall.

Nel grafico sono riportate le tre classi del dataset:

Classe	mAP@0.5
crack	0.679
dent	0.426
scratch	0.223
tutte le classi	0.443

Nella Figura sopra si osserva che la classe **crack** è quella con la curva migliore. Il valore di **mAP@0.5 pari a 0.679** conferma che il modello riesce a riconoscere le crepe in modo più efficace rispetto alle altre classi. La

curva rimane alta per una buona parte dei valori di recall, indicando che il modello mantiene una precisione abbastanza elevata anche quando aumenta il numero di crepe rilevate.

La classe **dent** ha un comportamento intermedio, con **mAP@0.5 pari a 0.426**. Questo significa che il modello riesce a rilevare alcune ammaccature, ma con prestazioni inferiori rispetto alle crepe. Le ammaccature possono essere più difficili da riconoscere perché spesso dipendono da variazioni di luce, ombre e deformazioni leggere della carrozzeria.

La classe più debole è **scratch**, con **mAP@0.5 pari a 0.223**. La curva scende più rapidamente rispetto alle altre classi, mostrando che il modello fatica a mantenere una buona precisione quando prova a rilevare più graffi. Questo risultato è coerente con la recall bassa osservata nella tabella dei risultati finali e con la matrice di confusione, dove molti scratch vengono confusi con il background.

Nel complesso, la curva media di tutte le classi ha un valore di **mAP@0.5 pari a 0.443**. Questo indica che il modello ha imparato a riconoscere i danni, ma le prestazioni sono fortemente influenzate dalla difficoltà della classe scratch.

8.2 Curva F1-Confidence




Figura 6 - Curva F1 al variare della confidence.

La Figura 6 mostra l'andamento della metrica **F1-score** al variare della soglia di **confidence**.

La **confidence** rappresenta il livello di sicurezza del modello rispetto a una predizione. Quando YOLO rileva un danno, assegna a quella predizione un valore di confidenza: più il valore è alto, più il modello è sicuro che il danno individuato sia corretto.

La curva F1-Confidence è utile perché permette di capire quale soglia di confidence produce il miglior equilibrio tra **precision** e **recall**.

La metrica **F1-score** combina precision e recall in un unico valore. È particolarmente utile quando si vuole valutare il comportamento complessivo del modello, senza considerare separatamente solo i falsi positivi o solo i falsi negativi.

Un valore alto di F1 indica che il modello riesce sia a fare predizioni corrette, sia a rilevare una buona parte dei danni presenti.

Nel grafico si osserva che la curva complessiva, rappresentata in blu spesso, raggiunge il valore massimo di circa **0.48** con una soglia di confidence pari a circa **0.314**. Questo significa che, per tutte le classi considerate insieme, il miglior compromesso tra precision e recall si ottiene usando una soglia di confidenza intorno a **0.31**.

Questo valore è importante perché aiuta a scegliere una soglia più adatta per la fase di predizione. Se la soglia di confidence è troppo bassa, il modello rileva più oggetti, ma aumenta il rischio di falsi positivi. Se invece la soglia è troppo alta, il modello accetta solo predizioni molto sicure, ma può perdere diversi danni reali, aumentando i falsi negativi.

Osservando le singole classi, si nota che **crack** ottiene i valori F1 più alti, la classe **dent** ha un andamento intermedio. La classe **scratch** è invece la più debole.

8.3 Curva Precision-Confidence




Figura 7 - Curva della precision al variare della confidence.

La Figura 7 mostra l'andamento della **precision** al variare della soglia di **confidence**.

Il grafico mostra che, aumentando la soglia di confidence, la precision tende ad aumentare. Questo comportamento è normale: se il modello accetta solo le predizioni di cui è molto sicuro, diminuisce il numero di falsi positivi, cioè di danni segnalati erroneamente.

Nel grafico si osserva che la curva media di tutte le classi raggiunge valori molto alti di precision con soglie elevate. In particolare, il valore indicato è circa **0.98** con confidence pari a **1.00**. Questo però non significa necessariamente che quella sia la soglia migliore da usare. A confidence molto alte, infatti, il modello mantiene solo pochissime predizioni molto sicure: queste possono essere corrette, ma molti danni reali vengono esclusi.

Per questo motivo la curva Precision-Confidence va letta insieme alla curva **Recall-Confidence** e alla curva **F1-Confidence**. La sola precision non basta per scegliere la soglia migliore, perché una precision molto alta può essere ottenuta anche facendo pochissime predizioni.

In sintesi, la Figura 7 mostra che aumentando la soglia di confidence il modello diventa più prudente e produce predizioni più affidabili. Tuttavia, usare una soglia troppo alta può far perdere molti danni reali. Per questo motivo, nella scelta della soglia finale è preferibile considerare un compromesso tra precision e recall, come mostrato dalla curva F1-Confidence.

8.4 Curva Recall-Confidence




Figura 8 - Curva della recall al variare della confidence.

La Figura 8 mostra l'andamento della **recall** al variare della soglia di **confidence**.

Nel grafico si osserva che la recall è più alta quando la soglia di confidence è bassa. Questo accade perché, con una soglia bassa, il modello accetta anche predizioni meno sicure e quindi rileva un numero maggiore di possibili danni. Tuttavia, in questo caso possono aumentare anche i falsi positivi.

Quando invece la soglia di confidence aumenta, il modello diventa più selettivo e accetta solo le predizioni di cui è molto sicuro. Di conseguenza, molte predizioni vengono scartate e la recall diminuisce. Questo significa che alcuni danni reali possono non essere più rilevati.

La curva complessiva, rappresentata in blu spesso, mostra che la recall media di tutte le classi diminuisce progressivamente all'aumentare della confidence. Nel grafico è indicato un valore massimo complessivo di circa **0.77** con confidence pari a **0.00**. Questo valore, però, non rappresenta necessariamente la scelta migliore per la soglia finale, perché una confidence troppo bassa può portare il modello a rilevare troppi oggetti, includendo anche predizioni sbagliate.

Osservando le singole classi, si nota che **crack** mantiene valori di recall più alti rispetto alle altre classi per gran parte dell'intervallo di confidence.

La classe **dent** presenta un andamento intermedio: la recall diminuisce gradualmente all'aumentare della confidence, indicando che alcune ammaccature vengono perse quando la soglia diventa più severa.

La classe **scratch** è quella con la recall più bassa. La curva scende rapidamente, mostrando che molti graffi vengono rilevati solo quando la soglia di confidence è molto bassa.

Questa curva va letta insieme alla curva **Precision-Confidence**. Infatti, aumentando la soglia di confidence, la precision tende ad aumentare, perché il modello accetta solo predizioni più sicure; però la recall diminuisce, perché vengono scartati anche alcuni danni reali. Al contrario, abbassando la soglia, la recall aumenta, ma la precision può peggiorare.

Per questo motivo, la soglia di confidence finale deve essere scelta cercando un equilibrio tra precision e recall. Nel caso di questo modello, la curva F1-Confidence suggerisce che una soglia intorno a **0.30** può rappresentare un buon compromesso.

9. Predizioni su immagini




Figura 9 - Esempi di predizione su immagini del validation set.

La Figura 9 mostra alcuni esempi di predizione ottenuti applicando il modello YOLO11n alle immagini del **validation set**. In questi esempi il modello disegna un **bounding box** attorno alla zona in cui rileva un possibile danno e assegna a ogni box una classe tra crack, dent e scratch.

Accanto alla classe viene mostrato anche un valore numerico, chiamato **confidence score**, che indica quanto il modello è sicuro della predizione. Ad esempio, una predizione crack 0.88 indica che il modello ha rilevato una crepa con confidenza pari a 0.88, quindi con un livello di sicurezza abbastanza alto.

Dagli esempi si può osservare che il modello riesce a individuare diversi tipi di danno:

- nell'immagine in alto a destra vengono rilevati sia una possibile **ammaccatura** (dent) sia alcuni **graffi** (scratch);
- nell'immagine in basso a sinistra il modello individua più regioni associate alla classe scratch;

- nell'immagine in basso a destra viene rilevata una **crepa** sul vetro con confidenza alta, pari a 0.88.

Questi risultati mostrano che il modello è in grado di localizzare i danni e di assegnare loro una classe, producendo quindi un output visivo facilmente interpretabile.

Tuttavia, gli esempi evidenziano anche alcuni limiti. In alcuni casi sono presenti più bounding box sovrapposti o vicini tra loro per lo stesso danno, soprattutto nella classe scratch. Questo può accadere perché i graffi possono essere estesi, irregolari o composti da più segni ravvicinati. Inoltre, alcuni valori di confidence sono medio-bassi, ad esempio dent 0.32 o scratch 0.26, indicando che il modello non è sempre molto sicuro della predizione.

L'immagine in alto a sinistra mostra invece una crepa evidente sul vetro, ma non è presente un bounding box visibile. Questo può rappresentare un possibile caso di **mancata rilevazione**, cioè un falso negativo: il danno è presente, ma il modello non lo segnala. Questo tipo di errore è importante da analizzare perché mostra che il modello, pur avendo imparato a riconoscere alcune tipologie di danno, non è ancora perfetto in tutti i casi.

Inoltre, sono state analizzate anche altre immagini al di fuori del dataset, di seguito alcune di queste:



10. Discussione dei risultati

I risultati ottenuti sono coerenti con un primo progetto di **object detection** applicato a immagini reali di danni automobilistici. Il modello YOLO11n riesce a individuare e classificare diversi danni alla carrozzeria, ma le prestazioni cambiano in modo significativo a seconda della classe considerata.

La classe riconosciuta meglio è **crack**, cioè le crepe. Questo risultato è plausibile, perché le crepe hanno spesso una forma più evidente, bordi più marcati e un contrasto maggiore rispetto alla superficie della carrozzeria o del vetro.

Le classi **dent** e soprattutto **scratch** risultano invece più difficili. Le ammaccature possono essere poco visibili, perché spesso dipendono da deformazioni leggere della carrozzeria, ombre o riflessi. I graffi, invece, sono ancora più complessi da rilevare perché possono essere sottili, piccoli, poco contrastati e facilmente confondibili con riflessi della luce, texture della vernice o linee naturali della carrozzeria.

Nel complesso, il modello mostra un comportamento positivo: riesce a riconoscere alcuni danni e produce bounding box interpretabili, ma non è ancora abbastanza robusto per gestire in modo affidabile tutti i casi, soprattutto quelli più ambigui o meno visibili.

11. Conclusione e possibili miglioramenti

Il progetto ha permesso di realizzare una pipeline completa per la **rilevazione automatica dei danni alla carrozzeria** tramite YOLO11.

Sono state svolte le principali fasi di un progetto di object detection: caricamento del dataset, controllo della struttura delle immagini e delle annotazioni, addestramento del modello, validazione, analisi delle metriche, generazione dei grafici di valutazione e test delle predizioni su immagini del validation set.

Per migliorare le prestazioni del sistema, si potrebbero introdurre diverse modifiche sia sul modello sia sul dataset.

Un primo miglioramento potrebbe essere l'utilizzo di un modello più grande, ad esempio **YOLO11s** o **YOLO11m**. Queste versioni hanno una maggiore capacità di apprendimento rispetto a YOLO11n e potrebbero riconoscere meglio danni piccoli o poco evidenti, anche se richiedono più tempo di training e più risorse computazionali.

Sarebbe inoltre utile aumentare il numero di immagini relative alle classi più difficili, soprattutto **scratch**. Anche se questa classe contiene molte istanze, i graffi sono molto variabili per forma, dimensione, colore e visibilità. Aggiungere immagini più rappresentative potrebbe aiutare il modello a riconoscerli meglio.

Si potrebbero poi aggiungere immagini più varie, includendo diverse condizioni di luce, angolazioni, colori della carrozzeria, qualità dell'immagine e tipi di danno. Questo renderebbe il modello più robusto e più adatto a scenari reali.

Infine, il sistema potrebbe essere esteso con una fase successiva capace di produrre una **descrizione testuale del danno rilevato**. Per esempio, a partire dall'output del modello, il sistema potrebbe generare una frase del

tipo: “È stato rilevato un graffio sulla parte laterale del veicolo con confidenza media”. Questa estensione renderebbe il progetto più vicino a un sistema intelligente completo.

In conclusione, il sistema sviluppato rappresenta una buona base di partenza per un’applicazione di riconoscimento automatico dei danni automobilistici. Le prestazioni possono essere migliorate attraverso modelli più grandi, un dataset più pulito e più vario, e un’eventuale integrazione con moduli intelligenti per la descrizione o la raccomandazione dell’intervento da effettuare

12. Bibliografia

<https://arxiv.org/abs/1506.02640>

<https://arxiv.org/abs/1512.02325>

<https://arxiv.org/abs/1506.01497>

<https://docs.ultralytics.com/models/yolo11>

<https://docs.ultralytics.com/modes/train>

<https://universe.roboflow.com/nibm-7v215/car-damage-detected-dataset-crackdentsctratch/dataset/1>

<https://docs.roboflow.com/datasets/dataset-versions/exporting-data>

<https://research.google.com/colaboratory/faq.html>